

6 주차 MLOps & Database

유주형

트랜잭션 데이터, 추천 검색 데이터, 운영 로그 데이터를 한 곳에 몰아넣지 않고 각 성격에 맞는 저장소를 분리한다. 그 위에 실험 추적, 환경 재현, 파이프라인 자동화, 성능 저하 감지와 재학습 루프를 붙여서 '노트북에서는 되는데 운영에서는 깨지는 문제'와 '문제가 생겨도 고객 불만이 쌓일 때까지 모르는 문제'를 동시에 줄이는 구조로 설계한다.

1. 기능별 최적의 데이터베이스 설계

투빅스타일은 단순 쇼핑몰이 아니라 이미지 기반 추천, 사용자 취향 누적, 운영 로그 분석이 동시에 필요한 서비스이다. 따라서 아래처럼 역할이 다른 저장소를 조합하는 편이 더 안정적이고 확장성이 좋다.

기능	추천 DB 유형	이유	저장 예시
주문, 결제, 포인트 정산	RDB 예: PostgreSQL	금전 정보와 재고 차감은 정합성이 가장 중요하다. 주문 생성, 결제 승인, 포인트 적립이 한 트랜잭션 안에서 묶여야 하므로 ACID 를 보장하는 관계형 DB 가 적합하다.	주문번호, 결제상태, 환불이력, 재고수량, 포인트 변동 내역
상품 메타데이터와 사용자 스타일 프로필	문서형 NoSQL 예: MongoDB	상품마다 속성 개수가 다르고, 브랜드 태그나 코디 설명처럼 구조가 자주 바뀐다. 사용자 취향 프로필도 클릭, 저장, 선호 카테고리처럼 반정형 데이터가 많아서 스키마 유연성이 중요하다.	상품 태그, 색상군, 계절, 핏 정보, 사용자 선호 브랜드, 금지 스타일
업로드 이미지 기반 유사 코디 검색	Vector DB 예: Milvus, pgvector	이미지 임베딩 간 최근접 이웃 검색이 핵심이다. 수천만 개 상품 임베딩 중 비슷한 스타일을 빠르게 찾아야 하므로 코사인 유사도나 inner product 에 최적화된 벡터 저장소가 가장 효율적이다.	상품 이미지 임베딩, 사용자 업로드 이미지 임베딩, 유사도 검색 인덱스
행동 로그 분석과 모델 모니터링	분석형 OLAP DB 예: ClickHouse, BigQuery	노출, 클릭, 저장, 구매 전환, 추천 실패 로그를 대량으로 적재하고 집계해야 한다. 운영팀과 데이터팀이 시간대별 지표를 즉시 봐야 하므로 대용량 집계에 강한 컬럼형 분석	추천 노출 로그, 클릭 로그, 추천 결과 CTR, 모델 버전별 성능 추세

		DB 가 유리하다.	
--	--	------------	--

요약

- RDB 는 주문과 결제처럼 틀리면 안 되는 데이터를 담당한다.
- Vector DB 는 추천 검색 속도를 책임진다. 상품 등록 시 임베딩을 만들고, 사용자 업로드 이미지와 가장 가까운 상품을 바로 찾는다.
- NoSQL 은 자주 바뀌는 상품 속성과 사용자 취향 메타데이터를 유연하게 정리한다.
- OLAP DB 는 운영 지표와 모델 품질 지표를 모두 모아 대시보드와 알림의 기반이 된다.

2. MLOps 도구를 활용한 'TO-BE' 인프라 구축

주어진 문제 A 는 재현성 부족, 문제 B 는 관측성 부족에서 나온다. 따라서 학습 환경을 표준화하고, 실험과 모델 버전을 추적하고, 파이프라인을 자동으로 돌리고, 성능이 떨어졌을 때 다시 학습까지 이어지는 루프를 만드는 것이 핵심이다.

도구	역할	투빅스타일 적용 방식	문제 해결
Docker	환경 격리와 재현성 확보	학습 이미지와 추론 이미지를 각각 Dockerfile 로 고정한다. Python 버전, CUDA, 라이브러리 버전, 시스템 패키지를 이미지에 명시하고, 노트북 실험도 같은 이미지를 기준으로 실행한다.	문제 A 해결에 직접적이다. '내 노트북에서는 되는데 서버에서는 안 되는' 버전 충돌을 크게 줄일 수 있다.
MLflow	실험 추적과 모델 레지스트리	학습마다 데이터 버전, 파라미터, Recall@K, CTR, 아티팩트를 기록한다. 통과한 모델만 Staging 에 등록하고, 운영 승인 후 Production 으로 승격한다.	문제 A 와 B 둘 다 도움을 줄 수 있다. 어떤 코드와 어떤 파라미터로 만든 모델이 운영 중인지 바로 추적 가능하다.
Apache Airflow	파이프라인 오케스트레이션	일 단위 혹은 시간 단위 DAG 로 데이터 적재, 전처리, 임베딩 생성, 학습, 평가, 배포 전 검증까지 순서대로 실행한다. 실패 시	운영 자동화가 가능해지고, 데이터 적재 실패나 평가 누락을 사람이 수동으로 확인하지 않아도 된다.

		재시도와 알림도 함께 설정한다.	
CT Pipeline	성능 저하 시 자동 재학습	운영 로그를 기반으로 CTR, 저장률, 전환율, 드리프트 지표를 계산하고, 기준선보다 일정 폭 이상 떨어지면 재학습 파이프라인을 자동 트리거한다. 새 모델은 기존 모델과 비교 평가 후 조건 충족 시에만 배포한다.	문제 B 해결의 핵심이다. 고객 불만이 올라오기 전에 시스템이 먼저 성능 하락을 감지하고 대응할 수 있다.

TO-BE 운영 흐름

- 1) 데이터 과학자는 Docker 기반 학습 환경에서 실험을 돌리고, 결과를 MLflow 에 기록한다.
- 2) 성능 측면에서 통과한 모델만 MLflow Registry 의 Staging 으로 등록한다.
- 3) Airflow 가 주기적으로 데이터 적재, 피처 생성, 임베딩 갱신, 평가 작업을 실행한다.
- 4) 운영 로그는 OLAP DB 에 쌓이고, 추천 품질과 드리프트를 계산한다.
- 5) 임계치 이하로 떨어지면 CT Pipeline 이 자동 재학습을 시작하고, 검증을 통과한 경우에만 Production 모델을 교체한다.

3. 운영팀과 데이터팀이 함께 보는 관리자 대시보드 설계

이 대시보드는 운영팀과 데이터팀이 각자 다른 화면을 보는 대신, 같은 숫자를 보면서 바로 협업할 수 있게 만드는 것이 목표다. 예를 들어, 운영팀은 장애와 지연시간을 보고, 데이터팀은 추천 품질과 드리프트를 위주로 보게 되겠지만, 결국 둘이 같은 모델 버전과 같은 로그를 기준으로 이야기 할 수 있는 환경이 갖추어 져야 한다.

대시보드 상단 KPI 카드

실시간 서비스 상태	운영 중 모델	추천 품질	경보 요약
API 지연시간 오류율 현재 QPS	Prod 모델 버전 배포 시각 사용 중 Docker 이미지	CTR 저장률 불만 접수 건수	임계치 초과 알림 최근 24 시간 심각도 표시

운영/분석 메인 패널

파이프라인 모니터링 Airflow DAG 성공/실패 현황 데이터 적재 시각과 최신성 피처 생성, 임베딩 생성, 배포 파이프라인 상태 재시도 필요 태스크 강조	모델 성능 추적 오프라인 Recall@K, Precision@K 온라인 CTR, 전환율, 클릭 후 이탈률 데이터 드리프트와 임베딩 분포 변화 기준선 대비 하락 폭 표시
MLflow 레지스트리 Staging / Production 버전 비교 실험 파라미터, 메트릭, 아티팩트 링크 승인자와 롤백 가능 버전 표시	CT 파이프라인 제어판 자동 재학습 트리거 사유 학습 중 / 검증 중 / 배포 완료 상태 휴먼 승인 여부와 최종 반영 결과

화면 구성 의도

- 상단 KPI 카드는 운영팀이 가장 먼저 보는 영역이다. 서비스 지연시간, 오류율, 현재 운영 모델 버전, 최근 경보 건수를 한눈에 보게 한다.
- 파이프라인 모니터링 영역은 Airflow 기준으로 데이터 적재와 학습 파이프라인이 정상인지 확인하는 패널이다. 여기서 막히면 추천 품질이 떨어지기 전에 원인을 먼저 찾을 수 있다.
- 모델 성능 추적 영역은 CTR, 저장률, 구매 전환율, 임베딩 드리프트 같은 지표를 함께 보여 준다. 단순 모델 정확도만 보는 것이 아니라 실제 서비스 반응까지 같이 봐야 한다.
- MLflow 레지스트리 박스는 현재 Production 모델과 직전 모델, 실험 링크, 롤백 후보를 연결해 준다. 장애가 났을 때 즉시 이전 버전으로 돌아갈 수 있어야 한다.
- CT 파이프라인 제어판은 성능 저하로 인해 재학습이 걸렸는지, 현재 어느 단계인지, 사람이 승인해야 하는지 보여 준다.

운영팀과 데이터팀이 같이 보게 되는 효과

- 운영팀은 오류 발생 탐지에서 멈추지 않고, 어떤 모델 버전과 어떤 파이프라인 실패가 원인인지 바로 확인할 수 있다.
- 데이터팀은 오프라인 성능은 좋았는데 운영 성능이 떨어진 원인을 로그와 대시보드에서 바로 추적할 수 있다.
- 같은 대시보드와 통합된 데이터를 보게 되므로, 문제 발생 시 책임 공방 대신 원인 추적과 대응 속도가 상승에 기여한다/